

# Sonda

## Manual técnico do projeto

Motor de busca de texto completo escrito do zero em C# e .NET 10, com índice invertido em disco e ranking BM25

Feito por Erik L. Pimenta

Versão 1.0.0 · Outubro de 2026 · Licença MIT

# Sumário


**1 Visão geral 4**

Para que serve 4

O que a Sonda faz 4

Ferramentas usadas 4

Identidade visual 5

**2 Conceitos 6**

Índice invertido 6

Análise de texto 6

Stemming RSLP e Porter 6

Relevância: BM25 e TF-IDF 7

WAND e saltos 7

**3 Como rodar 8**

Pré-requisitos 8

Primeira execução no Windows 8

Primeira execução no Linux e no macOS 8

Com Docker 8

Sem os scripts 9

Parar e limpar 9

**4 Guia do painel 10**

Busca 10

Explicação da pontuação 11

Visualizar documento 12

Visão geral do índice 13

Fontes 14

Termos 15

Tema escuro e celular 16

**5 Sintaxe de busca 17**

Operadores 17

Dicas 17

**6 Linha de comando 18**

Comandos 18

Exemplos 19

**7 API REST 20**

Rotas 20

Exemplos 21

**8 Configuração 22**

Opções 22

Variáveis do Docker 23

**9 Desempenho e ajuste 24**

Resultados 24

Como ajustar 24

**10 Testes, CI e automação 25**

Testes 25

Integração contínua 25

Atividade diária 25

**11 Segurança e privacidade 27**

**12 Solução de problemas 28**

Capítulo 1

# Visão geral

A Sonda é um motor de busca de texto completo no estilo Lucene e Elasticsearch, escrita do zero em C#. Ela varre pastas com arquivos `.txt`, `.md` e `.html`, extrai o texto, quebra em termos, reduz cada palavra ao radical e grava um índice invertido binário em disco. As buscas voltam ordenadas por relevância em poucos milissegundos, com trechos destacados e explicação da pontuação.

## Para que serve

Para encontrar informação em grandes volumes de documentos sem depender de `LIKE '%texto%'` num banco SQL, que lê todas as linhas, não entende plural nem acento e devolve os resultados sem nenhuma ordem de relevância.

O repositório entrega a estrutura, a arquitetura, a documentação e a ferramenta pronta para rodar. Quem usa decide quais pastas indexar, em que máquina, com qual porta, idioma, memória e chave de acesso.

## O que a Sonda faz

- **Análise de texto própria:** tokenização Unicode, minúsculas, remoção de acentos, stopwords em português e inglês, stemming RSLP (português) e Porter (inglês) e detecção automática do idioma de cada documento.
- **Índice invertido em disco:** segmentos imutáveis gravados com `FileStream` em formato binário próprio, com codificação delta, inteiros de tamanho variável, blocos de 128 empacotados em bits, tabelas de saltos, campos armazenados comprimidos com Brotli e checksum CRC32 em todos os arquivos.
- **Indexação paralela:** uma tarefa varre as pastas e vários consumidores da Task Parallel Library analisam os arquivos ao mesmo tempo, gravando num buffer compartilhado em `ConcurrentDictionary`.
- **Relevância:** BM25 (padrão) ou TF-IDF clássico, peso maior para o título, estatísticas globais entre segmentos e explicação detalhada de cada pontuação.
- **Consultas:** todos ou qualquer termo, frases exatas e com distância, prefixos, busca aproximada com distância de edição, exclusão, grupos, campos, pesos e filtros por tipo, idioma e fonte.
- **WAND:** nas buscas por qualquer termo, o algoritmo pula documentos que não têm como entrar no top 10.
- **Indexação incremental:** arquivos sem mudança são pulados, alterados são substituídos e removidos saem do índice. Pastas podem ser observadas e reindexadas sozinhas.
- **Manutenção automática:** mesclagem de segmentos em segundo plano, remoção definitiva de excluídos e verificação de integridade.
- **Painel web** em HTML, CSS e JavaScript puros, servido pelo próprio ASP.NET Core, com tema claro e escuro e layout para celular. Também há API REST e ferramenta de linha de comando.

## Ferramentas usadas

| Ferramenta | Versão | Papel no projeto |
|---|---|---|
| C# e .NET | .NET 10 | Linguagem e plataforma de todo o motor, do servidor, da linha de comando e dos testes |

| Ferramenta | Versão | Papel no projeto |
|---|---|---|
| Task Parallel Library | .NET 10 | `Parallel.ForEachAsync` e `Parallel.For` distribuem a análise de documentos entre os núcleos |
| System.Threading.Channels | .NET 10 | Fila limitada entre o varredor de pastas e os consumidores, com contrapressão |
| ConcurrentDictionary | .NET 10 | Buffer de termos em memória, cache de radicais, mapa de chaves e estatísticas |
| FileStream e RandomAccess | .NET 10 | Gravação sequencial dos segmentos e leitura posicional sem travas pelos leitores |
| System.IO.Compression (Brotli) | .NET 10 | Compressão dos blocos de campos armazenados |
| ASP.NET Core | .NET 10 | API REST com Minimal APIs, eventos em tempo real (Server-Sent Events) e hospedagem do painel |
| HTML, CSS e JavaScript | ES2022 | Painel sem frameworks nem CDN, com a fonte Archivo incluída no projeto |
| xUnit | 2.9 | Testes de análise, armazenamento, busca, concorrência, mesclagem e indexação de pastas |
| Docker | Compose v2 | Imagem multiestágio com SDK para compilar e ASP.NET para rodar |
| GitHub Actions | — | Integração contínua e a automação de atividade diária |

O motor não usa nenhum pacote NuGet externo: tokenizador, stemmers, extrator de HTML, codecs binários, CRC32, parser de consultas, pontuação, WAND e destaque de trechos foram escritos do zero.

## Identidade visual

O painel segue a paleta do Doca: fundo cinza-claro, painéis brancos, bordas finas e um único tom de destaque, o azul-marinho `#2B4C7E`, usado no item ativo do menu, nas barras, nos termos destacados e no foco do teclado. A marca, um prumo de sondagem descendo com duas ondas de sonar, é sempre em preto e branco.

**#F3F4F6** fundo das páginas

**#FFFFFF** painéis e tabelas

**#E1E4E8** bordas e divisórias

**#5B626B** textos de apoio

**#16191D** texto e botões

**#2B4C7E** destaque e foco

Capítulo 2

# Conceitos

O que acontece entre um arquivo na pasta e um resultado na tela.

## Índice invertido

Um índice invertido guarda, para cada termo, a lista ordenada dos documentos em que ele aparece, com a frequência e as posições. Buscar “índice invertido” vira ler duas listas e cruzar as duas, em vez de ler todos os documentos.

A Sonda divide o índice em **segmentos**. Cada segmento é um índice completo e imutável. Documentos novos ficam num buffer em memória e viram um segmento quando o buffer enche ou quando há um commit. Exclusões ficam num mapa de bits à parte, e segmentos pequenos são mesclados em segundo plano.

## Análise de texto

```
"Os Motores de BUSCA indexaram páginas"
  │ tokenização        Os | Motores | de | BUSCA | indexaram | páginas
  │ minúsculas         os | motores | de | busca | indexaram | páginas
  │ stopwords          —  | motores | —  | busca | indexaram | páginas   (posições mantidas)
  │ remoção de acentos    | motores |    | busca | indexaram | paginas
  └ stemming (RSLP)       | motor   |    | busc  | index     | pagin
```

A mesma análise roda na indexação e na consulta, então quem procura “páginas indexadas” encontra o documento acima. As palavras descartadas continuam contando posição, para que as frases respeitem a distância original.

O idioma de cada documento é detectado pela proporção de palavras funcionais de cada língua (ou pelo atributo `lang` do HTML). No modo automático, cada palavra da consulta gera as duas variantes, português e inglês, combinadas como sinônimos.

## Stemming RSLP e Porter

| Palavra | Radical | Regra aplicada |
|---|---|---|
| casas, casa | `cas` | plural e vogal final |
| professora, professor | `profes` | feminino e depois sufixo de substantivo |
| canções, canção | `canca` | plural *ões* e aumentativo com exceção |
| indexação, indexado, indexar | `index` | sufixos de substantivo e verbo |
| rapidamente | `rapid` | sufixo de advérbio |
| searching, searches | `search` | Porter, passo 1 |
| generalizations | `gener` | Porter, passos 1 a 4 |

O RSLP roda sobre o texto já sem acentos, com as regras convertidas da mesma forma. Assim “relevancia” e “relevância” chegam ao mesmo radical, o que importa muito para quem digita sem acento.

## Relevância: BM25 e TF-IDF

```
BM25(t, d) = boost × idf(t) × freq × (k1 + 1) / (freq + k1 × (1 − b + b × dl / avgdl))
idf(t) = ln(1 + (N − df + 0,5) / (df + 0,5))
```

**freq** é quantas vezes o termo aparece no campo, **dl** o tamanho do campo, **avgdl** o tamanho médio, **N** os documentos com o campo e **df** os que contêm o termo. Os padrões são k1 = 1,2 e b = 0,75. O título recebe peso 2.

```
TF-IDF(t, d) = boost × √freq × idf(t)² × 1/√dl     idf(t) = 1 + ln((N + 1) / (df + 1))
```

O BM25 satura a frequência: a décima ocorrência vale bem menos que a primeira. No TF-IDF clássico, repetir uma palavra cem vezes rende pontos demais. Dá para alternar entre os dois no painel, na API e na linha de comando.

## WAND e saltos

Cada termo guarda a maior pontuação possível que ele pode dar (calculada pela maior frequência e pelo menor campo da lista). Numa busca por qualquer termo, o algoritmo WAND ordena os cursores pelo documento atual e só avalia um documento quando a soma dos máximos dos termos que podem estar nele supera a menor pontuação do top 10. Documentos sem chance são pulados com as tabelas de saltos.

Em 100 mil documentos, uma busca por três termos avalia em média 756 documentos com WAND contra 30.809 na busca exaustiva. Quando o painel precisa da contagem exata e das facetas, a busca exaustiva é usada.

Capítulo 3

# Como rodar

A Sonda roda com o .NET SDK 10 instalado ou com Docker. Os scripts de início escolhem sozinhos o que estiver disponível.

## Pré-requisitos

- **.NET SDK 10** (recomendado): baixe em dot.net e confira com `dotnet --list-sdks`.
- **Ou Docker**: Docker Desktop no Windows e no macOS, Docker Engine com o plugin compose no Linux.
- Git para clonar o repositório.

## Primeira execução no Windows

1. Clone o repositório: `git clone https://github.com/ravelroot/Inverted-Index-Search-Engine.git`.
2. Abra a pasta e dê dois cliques em `iniciar.cmd`.
3. O script cria o `.env` a partir do `.env.example` e gera uma chave de acesso aleatória.
4. Com o .NET SDK 10 instalado, ele compila e inicia o servidor; sem o SDK, sobe o Docker.
5. O navegador abre em **http://localhost:8080** com os 30 documentos de exemplo já indexados. A chave aparece no terminal.

## Primeira execução no Linux e no macOS

1. Clone o repositório e entre na pasta.
2. Rode `./iniciar.sh`.
3. Acesse **http://localhost:8080**.

## Com Docker

1. Copie `.env.example` para `.env`.
2. Em `SONDA_DOCUMENTOS`, coloque a pasta do seu computador que será indexada (somente leitura dentro do contêiner).
3. Preencha `SONDA_API_KEY` com uma chave longa e aleatória.
4. Rode `docker compose up -d --build` e acesse **http://localhost:8080**.

O índice fica no volume `sonda-dados`. A porta é presa a `127.0.0.1`, então só a própria máquina acessa.

### Sem os scripts

```
dotnet build src/Sonda.Server -c Release
dotnet src/Sonda.Server/bin/Release/net10.0/Sonda.Server.dll

dotnet run --project src/Sonda.Cli -- indexar C:\Documentos --fonte documentos
dotnet run --project src/Sonda.Cli -- buscar "índice invertido"
```

Caminhos relativos do appsettings são resolvidos a partir da raiz do repositório (a pasta que tem o `Sonda.slnx`) ou da variável `SONDA_BASE`.

### Parar e limpar

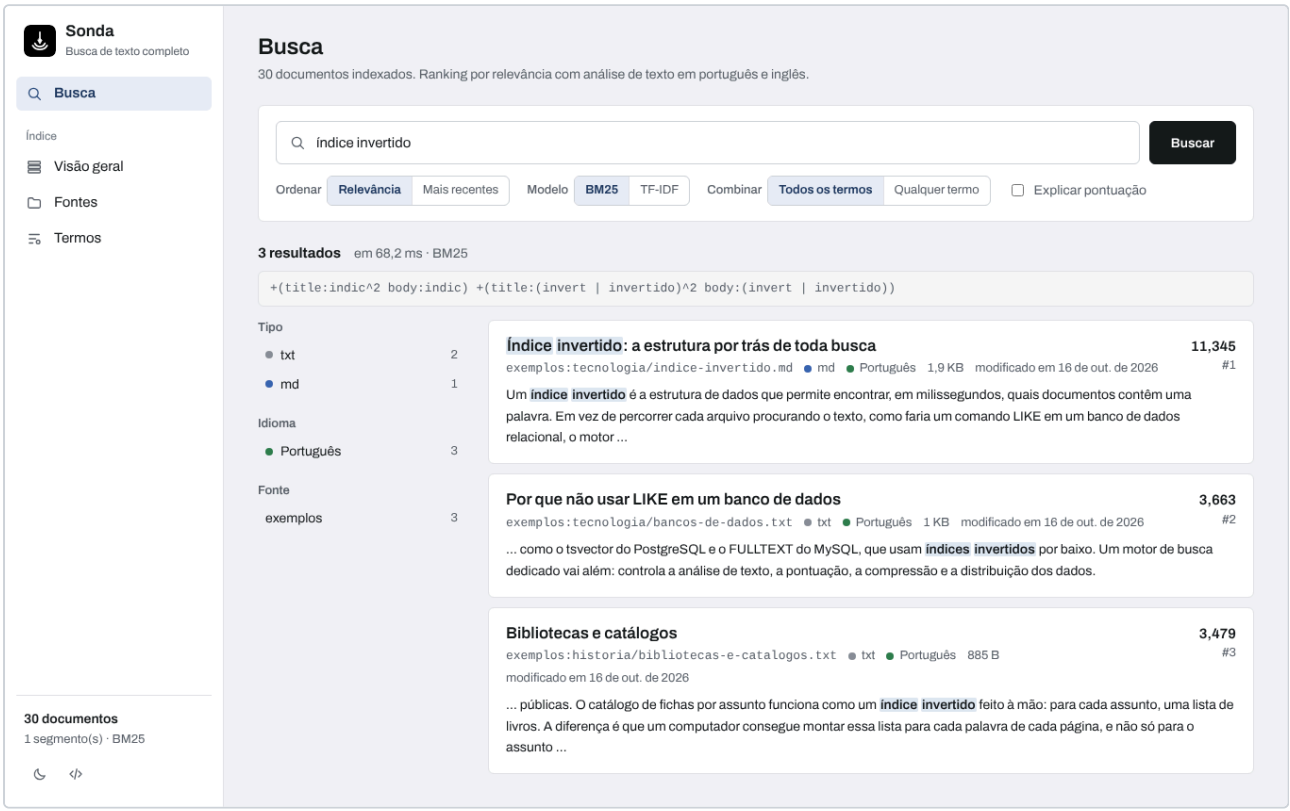
- Servidor local: feche a janela ou aperte Ctrl+C. O buffer em memória é gravado antes de sair.
- Docker: `docker compose down` para parar e `docker compose down -v` para apagar o índice.
- Para recomeçar do zero sem Docker, apague a pasta `dados/`.

Capítulo 4

# Guia do painel

O painel tem quatro telas: Busca, Visão geral, Fontes e Termos. O menu lateral mostra quantos documentos e segmentos existem e o modelo de relevância em uso.

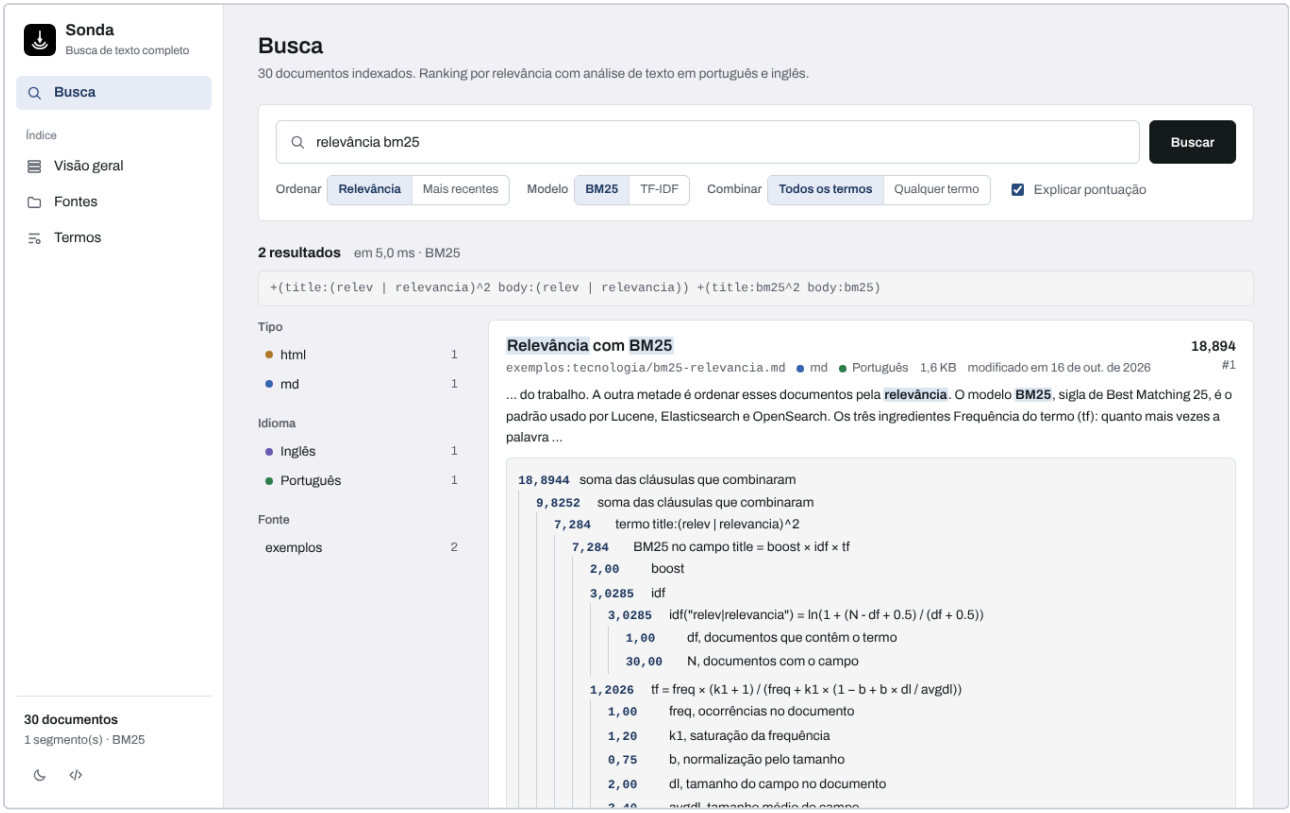
## Busca




Resultados para “índice invertido”: facetas à esquerda, título e trechos com os termos destacados e a pontuação à direita.

- **Ordenar:** por relevância ou pelos arquivos modificados mais recentemente.
- **Modelo:** BM25 ou TF-IDF, sem reindexar.
- **Combinar:** todos os termos ou qualquer termo. Se nenhum documento tiver todos, a busca é ampliada sozinha e um aviso aparece.
- **Consulta interpretada:** mostra como a consulta ficou depois da análise: radicais, campos, pesos e operadores.
- **Facetas:** tipo, idioma e fonte com a contagem de resultados. Um clique filtra; outro clique remove o filtro.

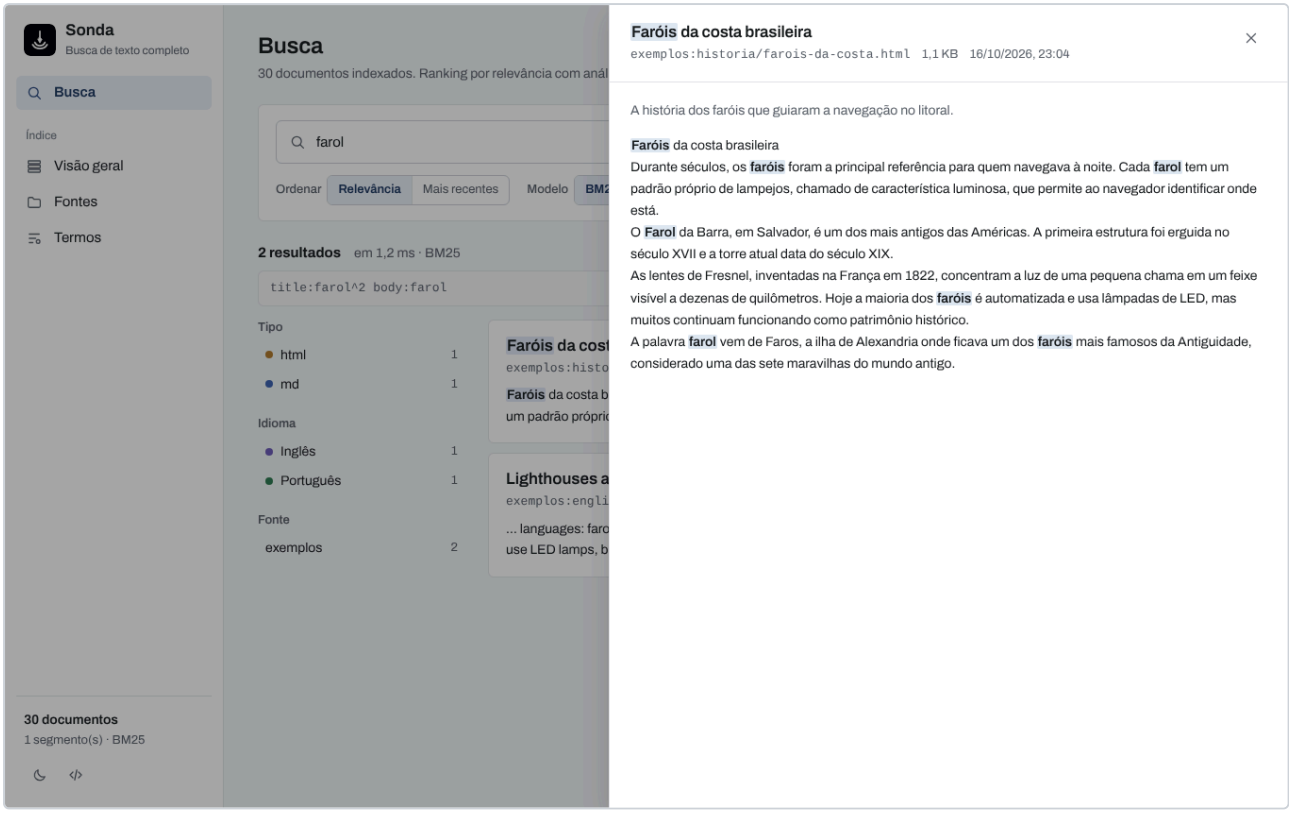
## Explicação da pontuação




Com Explicar pontuação marcado, cada resultado mostra a árvore de cálculo: boost, idf com df e N, e tf com frequência, k1, b, dl e avgdl.

A soma dos valores da árvore é exatamente a pontuação exibida no resultado.

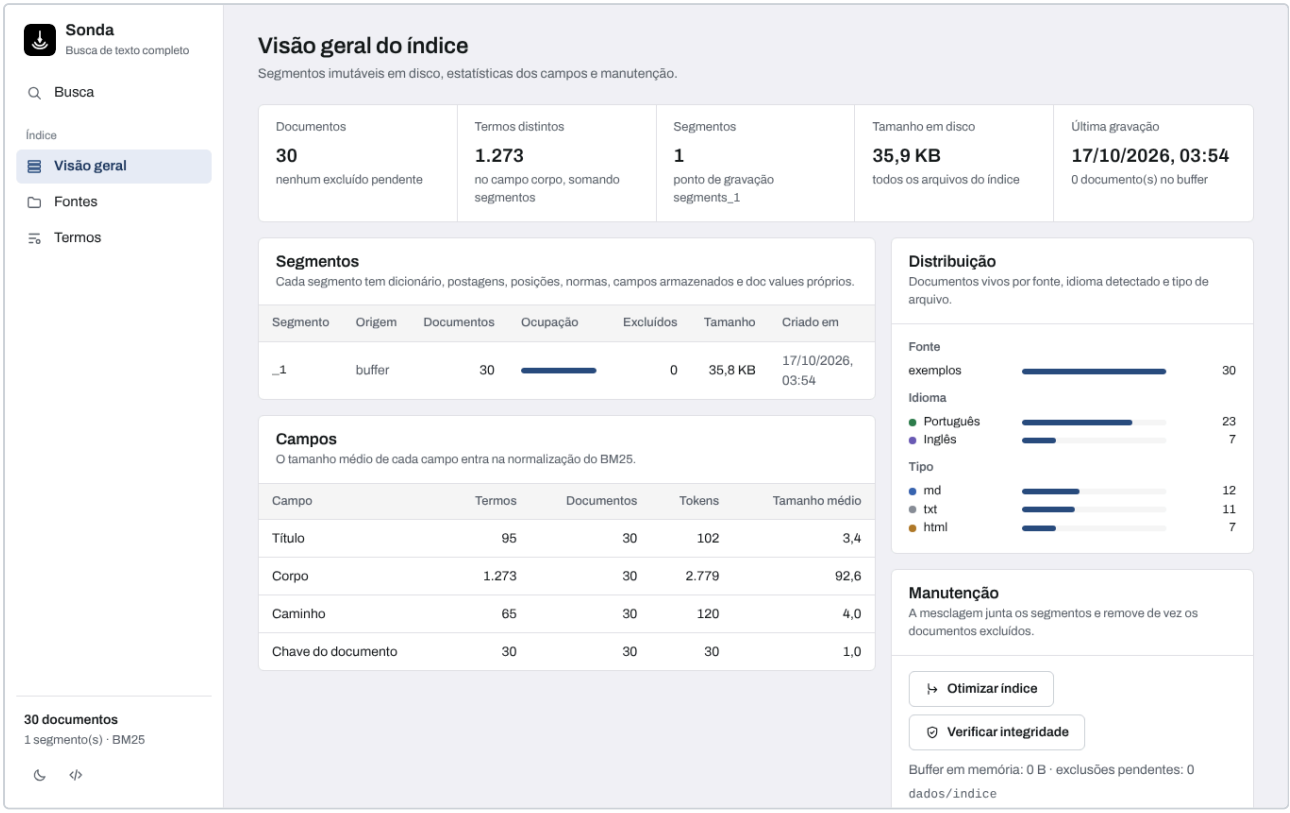
## Visualizar documento




Clicar no título abre o texto completo com todas as ocorrências destacadas.

Esc ou um clique fora da gaveta fecha a visualização. Documentos muito longos mostram os primeiros 60 mil caracteres.

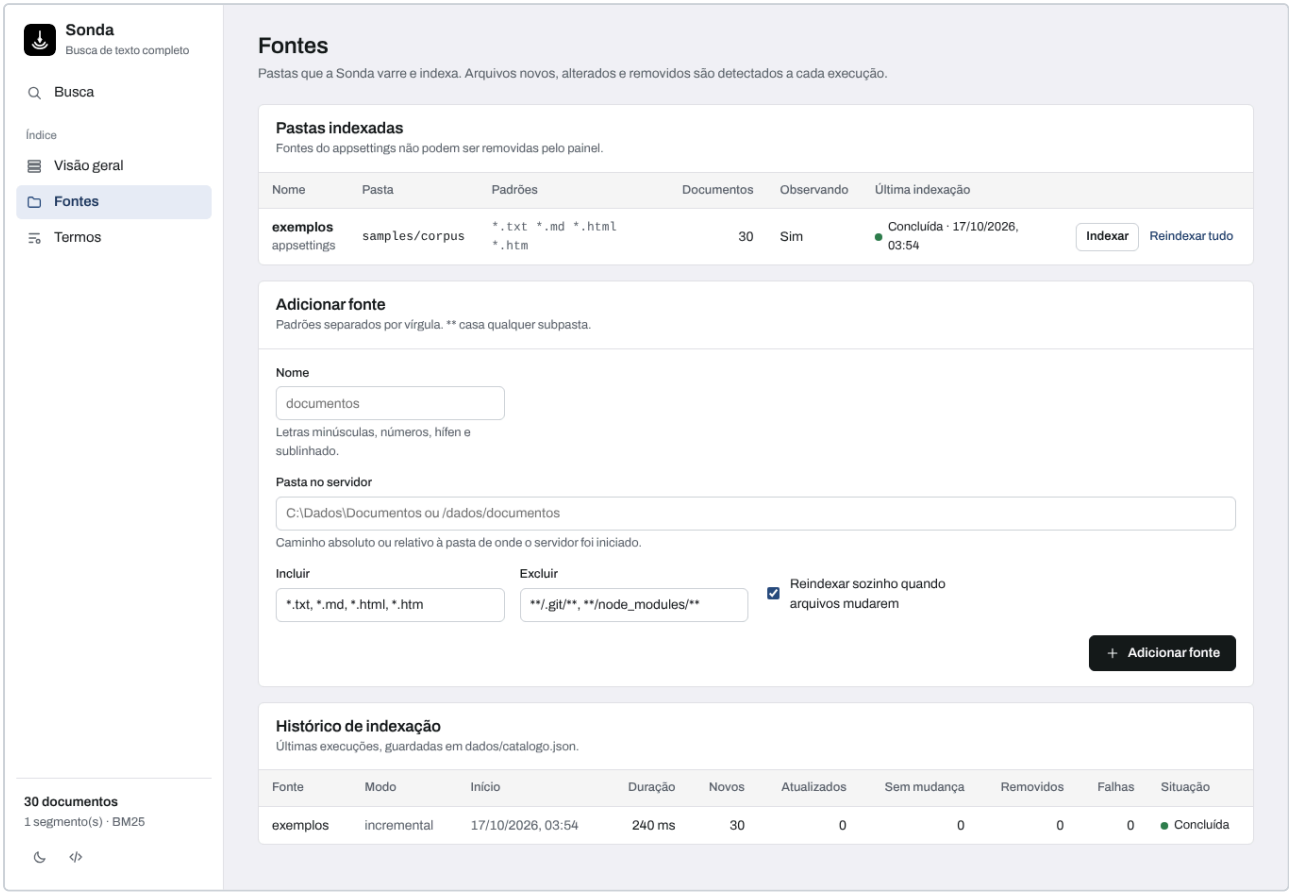
## Visão geral do índice




Segmentos, campos, distribuição dos documentos e manutenção.

- **Segmentos:** nome, origem (buffer ou mesclagem), documentos, proporção de excluídos, tamanho e data.
- **Campos:** termos distintos, documentos, tokens e tamanho médio, usado no BM25.
- **Otimizar índice:** mescla todos os segmentos em um e remove de vez os excluídos.
- **Verificar integridade:** confere o CRC32 de todos os arquivos do ponto de gravação atual.

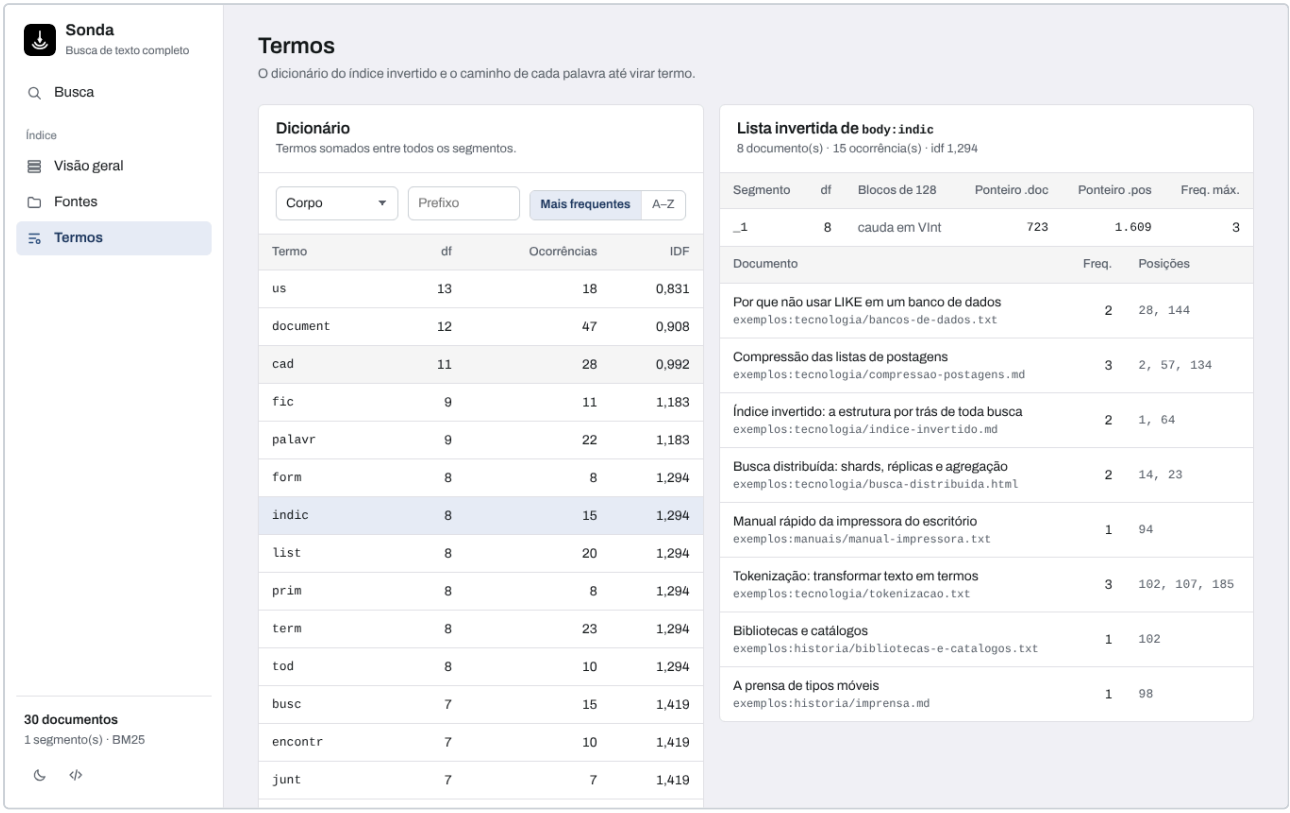
## Fontes




Pastas indexadas, cadastro de novas fontes e histórico das execuções.

- **Indexar:** varredura incremental, que pula arquivos com a mesma data e tamanho.
- **Reindexar tudo:** reprocessa todos os arquivos da fonte.
- **Adicionar fonte:** nome, pasta no servidor, padrões de inclusão e exclusão e a opção de observar alterações.
- Durante a indexação aparece o progresso em tempo real: arquivos encontrados, lidos, novos, atualizados, vazão e arquivo atual, com botão para cancelar.
- Se o servidor tiver chave de acesso, o painel pede a chave antes de qualquer alteração. Ela fica só na memória da aba.

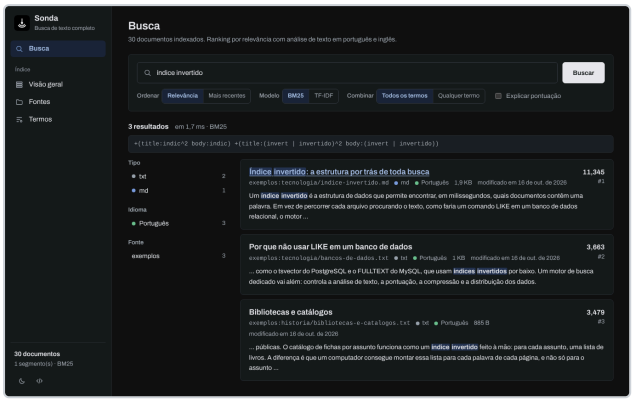
## Termos




O dicionário do campo corpo e a lista invertida do termo “indic”.

- **Dicionário:** termos de um campo com df, ocorrências e idf, por frequência ou em ordem alfabética, com filtro por prefixo.
- **Lista invertida:** para o termo escolhido, os segmentos com ponteiros nos arquivos `.doc` e `.pos`, blocos de 128, frequência máxima, e os documentos com as posições de cada ocorrência.
- **Analisador:** mostra o caminho de cada palavra até virar termo, com os radicais em português e inglês e as stopwords descartadas.

## Tema escuro e celular




Tema escuro com os mesmos tons ajustados.




Layout para celular.

O botão com a lua no rodapé do menu alterna o tema; a escolha fica guardada no navegador.

Capítulo 5

# Sintaxe de busca

A sintaxe segue o Lucene, com operadores também em português. Os operadores precisam estar em maiúsculas.

## Operadores

| Consulta | O que faz |
|---|---|
| `motor busca` | Todos os termos (padrão). Com stemming, encontra “motores de buscas” |
| `motor OR busca` · `motor OU busca` | Qualquer um dos termos |
| `motor AND busca` · `motor E busca` | Todos os termos, mesmo com o operador padrão OU |
| `+motor busca` | `motor` obrigatório, `busca` opcional (aumenta a pontuação) |
| `bm25 -tfidf` · `bm25 NOT tfidf` · `NAO` | Exclui documentos com o termo |
| `"índice invertido"` | Frase exata, na ordem |
| `"motor relevância"~4` | Frase com até 4 posições de folga; ordem invertida custa mais |
| `busc*` | Prefixo; também casa radicais menores que o prefixo, como `busc` para `buscan*` |
| `algoritimo~` · `algoritimo~1` | Busca aproximada com até 2 (ou o número dado) edições, incluindo troca de letras vizinhas |
| `(feijoada OR moqueca) receita` | Grupos com parênteses |
| `farol^3 navio` · `(a b)^2` | Peso extra para um termo ou grupo |
| `titulo:farol` · `corpo:` · `caminho:` | Busca só no campo. Aceita title, body e path |
| `tipo:html` · `idioma:en` · `fonte:exemplos` | Filtros exatos, que não mudam a pontuação |

## Dicas

- Palavras muito comuns, como *de*, *para* e *the*, são ignoradas. Uma consulta só com elas não traz resultados.
- Acentos e maiúsculas não importam.
- Use frases quando a ordem das palavras importa e o operador OU quando qualquer termo serve.
- A consulta interpretada mostra exatamente o que foi procurado. Ela é a melhor ferramenta para entender um resultado inesperado.

Capítulo 6

# Linha de comando

A ferramenta `sonda` usa o mesmo motor do servidor. Comandos de leitura funcionam mesmo com o servidor aberto; os de escrita exigem que ele esteja parado, porque só um processo pode gravar no índice.

## Comandos

| Comando | O que faz |
|---|---|
| `indexar <pasta>` | Indexa a pasta. Opções: `--fonte`, `--incluir`, `--excluir`, `--completo`, `--paralelismo`, `--idioma auto\|pt\|en\|nenhum`, `--ram`, `--max-mb` |
| `buscar "consulta"` | Busca. Opções: `--top`, `--pagina`, `--tfidf`, `--ou`, `--explicar`, `--recentes`, `--tipo`, `--fonte`, `--json` |
| `estatisticas` | Documentos, segmentos, campos, tamanho e distribuição. `--json` |
| `termos` | Dicionário de um campo: `--campo`, `--prefixo`, `--limite`, `--frequencia` |
| `postagens <termo>` | Lista invertida de um termo, com ponteiros, blocos e posições |
| `analisar "texto"` | Tokenização, stopwords e radicais RSLP e Porter |
| `otimizar` | Mescla os segmentos (`--segmentos 1`) e remove excluídos |
| `verificar` | Confere o checksum CRC32 de todos os arquivos |
| `remover-fonte <nome>` | Remove do índice os documentos de uma fonte |
| `benchmark` | Gera um corpus sintético, indexa e mede consultas: `--docs`, `--consultas`, `--manter` |

Opção comum a todos: `--indice <pasta>`, ou a variável `SONDA_INDICE`. O padrão é `dados/indice`.

## Exemplos

```
$ sonda indexar samples/corpus --fonte exemplos
Encontrados  Novos  Atualizados  Sem mudança  Removidos  Falhas  Lidos    Tempo
30           30     0            0            0          0       30,0 KB  0,17 s

$ sonda buscar "relevância bm25" --top 3
2 resultado(s) · BM25
Consulta interpretada: +(title:(relev | relevancia)^2 body:(relev | relevancia)) +(title:bm25^2
body:bm25)
  1. Relevância com BM25
     exemplos:tecnologia/bm25-relevancia.md · md · pt · 1,6 KB · pontuação 18,894
  2. Ranking functions: TF-IDF and BM25
     exemplos:english/ranking-functions.html · html · en · 1,1 KB · pontuação 10,173

$ sonda postagens indic --campo corpo --limite 3
body:indic · df 8 · ocorrências 15 · idf 1,294
Documento                                  Freq.  Posições
exemplos:tecnologia/bancos-de-dados.txt      2      28, 144
exemplos:tecnologia/compressao-postagens.md  3      2, 57, 134
exemplos:tecnologia/indice-invertido.md      2      1, 64
```

Capítulo 7

# API REST

Todas as respostas são JSON. Com `Sonda:Api:ApiKey` definido, rotas que alteram o índice exigem o cabeçalho `X-Sonda-Key`; com `ProtectReads`, as de leitura também.

## Rotas

| Método | Rota | Função |
|---|---|---|
| GET | `/api/busca?q=&pagina=&tamanho=&ordem=&similaridade=&operador=&explicar=&tipo=&idioma=&fonte=` | Busca com trechos, facetas e, opcionalmente, explicação |
| GET | `/api/documentos/{chave}?q=` | Documento completo com destaques. A chave vai em Base64 URL |
| GET | `/api/indice` | Estatísticas do índice, segmentos e campos |
| POST | `/api/indice/otimizar?segmentos=1` | Mesclagem forçada |
| POST | `/api/indice/verificar` | Verificação de checksums |
| GET | `/api/termos?campo=&prefixo=&limite=&ordem=` | Dicionário |
| GET | `/api/termos/postagens?campo=&termo=&limite=` | Lista invertida de um termo |
| GET | `/api/analise?texto=` | Análise de texto passo a passo |
| GET · POST | `/api/fontes` | Lista e cadastra fontes |
| DELETE | `/api/fontes/{nome}` | Remove uma fonte do catálogo e seus documentos |
| POST | `/api/fontes/{nome}/indexar?modo=incremental\|completa` | Agenda uma indexação |
| GET · POST | `/api/indexacao` · `/api/indexacao/cancelar` | Estado da fila e cancelamento |
| GET | `/api/execucoes?limite=` | Histórico de indexação |
| GET | `/api/eventos` | Server-Sent Events: progresso, fila, execucao e indice |
| GET | `/api/info` · `/health` | Informações do servidor e sonda de vida |

## Exemplos

```
curl "http://localhost:8080/api/busca?q=%22inverted%20index%22&tamanho=5"

curl -X POST http://localhost:8080/api/fontes \
  -H "Content-Type: application/json" -H "X-Sonda-Key: <sua chave>" \
  -d '{"nome":"manuais","caminho":"/dados/manuais","incluir":["*.md","*.html"],"observar":true}'

curl -X POST "http://localhost:8080/api/fontes/manuais/indexar?modo=completa" -H "X-Sonda-Key:
<sua chave>"
```

Erros seguem o padrão Problem Details (RFC 9457), com `title` e `detail` em português. Uma consulta com parêntese aberto, por exemplo, devolve 400 com a explicação do problema.

Capítulo 8

# Configuração

As opções ficam em `src/Sonda.Server/appsettings.json` e podem ser sobrescritas por variáveis de ambiente com dois sublinhados, como `Sonda__Search__Similarity=TFIDF`.

## Opções

| Opção | Padrão | Função |
|---|---|---|
| `Urls` | http://127.0.0.1:8080 | Endereço do servidor |
| `Sonda:IndexPath` · `DataPath` | dados/indice · dados | Pasta do índice e do catálogo |
| `Sonda:Analysis:Language` | auto | auto, pt, en ou nenhum (sem stemming) |
| `Sonda:Analysis:DefaultLanguage` | pt | Idioma quando a detecção não decide |
| `Sonda:Analysis:StopWords` · `FoldAccents` | true · true | Remoção de stopwords e de acentos |
| `Sonda:Indexing:RamBufferMb` | 128 | Memória do buffer antes de gravar um segmento |
| `Sonda:Indexing:Parallelism` | 0 | Threads de análise; 0 usa todos os núcleos |
| `Sonda:Indexing:MaxFileMb` | 32 | Arquivos maiores são ignorados e aparecem como falha |
| `Sonda:Indexing:StoreBody` | true | Guarda o texto para trechos e visualização |
| `Sonda:Indexing:MergeFactor` · `AutoMerge` | 10 · true | Quantos segmentos disparam uma mesclagem |
| `Sonda:Indexing:IndexOnStartup` | true | Indexação incremental de todas as fontes ao iniciar |
| `Sonda:Indexing:WatchDebounceSeconds` | 3 | Espera após a última alteração antes de reindexar |
| `Sonda:Search:Similarity` | BM25 | BM25 ou TFIDF |
| `Sonda:Search:K1` · `B` | 1,2 · 0,75 | Parâmetros do BM25 |
| `Sonda:Search:TitleBoost` | 2 | Peso do título em relação ao corpo |
| `Sonda:Search:DefaultOperator` | And | And ou Or |
| `Sonda:Search:MaxResultWindow` · `SnippetLength` | 1000 · 240 | Resultados navegáveis e tamanho do trecho |
| `Sonda:Api:ApiKey` · `ProtectReads` | vazio · false | Chave de acesso e proteção também das leituras |

| Opção | Padrão | Função |
|---|---|---|
| `Sonda:Api:AllowedOrigins` | vazio | Origens liberadas para CORS |
| `Sonda:AllowedRoots` | vazio | Se preenchido, novas fontes precisam estar dentro dessas pastas |
| `Sonda:Sources` | exemplos | Fontes fixas: Name, Path, Include, Exclude e Watch |

## Variáveis do Docker

| Variável | Função |
|---|---|
| `SONDA_PORT` | Porta no computador (padrão 8080) |
| `SONDA_API_KEY` | Chave de acesso; os scripts geram uma aleatória |
| `SONDA_DOCUMENTOS` | Pasta do computador montada como somente leitura e indexada |
| `SONDA_IDIOMA` · `SONDA_RAM_MB` | Idioma da análise e memória do buffer |

Capítulo 9

# Desempenho e ajuste

Números do comando `sonda benchmark` numa máquina com 2 vCPUs Xeon a 2,1 GHz, com 100 mil documentos sintéticos de 80 a 600 palavras e 1.000 consultas de 1 a 3 termos.

## Resultados

| Medida | Resultado |
|---|---|
| Indexação | 18,8 s · 5.333 documentos/s · 16,3 MB/s de texto |
| Mesclagem para 1 segmento | 9,6 s |
| Tamanho do índice | 176,9 MB, com o texto completo armazenado |
| OU exato com contagem e facetas | p50 2,98 ms · p95 6,36 ms · 30.809 documentos avaliados |
| OU top 10 com WAND | p50 2,24 ms · p95 3,61 ms · 756 documentos avaliados |
| E com saltos | p50 2,17 ms · p95 4,45 ms |
| E com trechos destacados | p50 2,99 ms · p95 4,78 ms |

## Como ajustar

- **Mais núcleos:** a indexação escala com `Parallelism`; o gargalo passa a ser o disco.
- **RamBufferMb maior** gera menos segmentos e menos mesclagens. Com pouca memória, use 32 ou 64.
- **StoreBody=false** reduz o índice pela metade, mas desliga os trechos e a visualização.
- **Otimizar** depois de uma carga grande deixa um segmento só e acelera as buscas.
- **Idioma fixo** (pt ou en) evita as duas variantes por palavra e deixa as consultas um pouco mais rápidas.
- Coloque a pasta `dados/` num SSD.

Capítulo 10

# Testes, CI e automação

O projeto tem 92 casos de teste xUnit, uma integração contínua e uma automação que grava atividade diária no repositório.

## Testes

| Arquivo | O que prova |
|---|---|
| AnalysisTests | Tokenização, remoção de acentos, Porter com os exemplos do artigo original, famílias de palavras no RSLP, exceções, detecção de idioma e extração de HTML e Markdown |
| StorageTests | CRC32 de referência, inteiros variáveis, blocos FOR de 0 a 31 bits, normas monotônicas, mapa de bits, detecção de byte corrompido e trava de escrita |
| SearchTests | Pontuação BM25 igual à fórmula, peso do título, frases, prefixo, busca aproximada, exclusão, filtros, facetas, ampliação automática, ordem por data, trechos, explicação e TF-IDF |
| IndexLifecycleTests | Visibilidade só depois do commit, reabertura, atualização, exclusão, mesclagem com excluídos, listas longas com saltos e limpeza de arquivos antigos |
| ConcurrencyTests | 6.000 documentos em 8 threads com vários flushes, buscas durante a indexação e WAND igual à busca exaustiva |
| QueryParserTests | Interpretação de cada operador, erros de sintaxe e distância de edição |
| PipelineTests | Indexação incremental de pastas reais: novos, alterados, removidos, completa e padrões de inclusão e exclusão |

```
dotnet test tests/Sonda.Tests
```

## Integração contínua

O arquivo `.github/workflows/ci.yml` roda a cada push na branch main: restaura, compila em Release com avisos tratados como erro, roda os testes, indexa os exemplos pela linha de comando, verifica os checksums, roda um benchmark curto e gera a imagem Docker.

## Atividade diária

O arquivo `.github/workflows/diario.yml` grava dois commits por dia em `.github/atividade.txt`. Cada commit tem um horário principal e um de reserva, que só grava se o principal não tiver rodado:

| Registro | Principal | Reserva | Cron (UTC) |
|---|---|---|---|
| 1º registro | 00:19 (Brasília) | 00:53 | `19 3 * * *` e `53 3 * * *` |
| 2º registro | 03:23 (Brasília) | 03:51 | `23 6 * * *` e `51 6 * * *` |

Os horários ficam na madrugada, fora do pico do GitHub Actions, em minutos quebrados (o começo de cada hora é o momento mais congestionado) e em faixas que nenhuma outra automação dos repositórios do autor usa, com pelo menos 30 minutos de distância de todas elas.

1. No GitHub, abra o repositório e vá em **Settings → Secrets and variables → Actions**.
2. Crie o secret `GIT_NAME` com o seu nome de usuário do GitHub.
3. Crie o secret `GIT_EMAIL` com o e-mail noreply do GitHub (*número+usuario@users.noreply.github.com*), para não expor o seu e-mail pessoal.
4. Em **Settings → Actions → General → Workflow permissions**, marque **Read and write permissions**.
5. Na aba **Actions**, abra *Atividade diária* e use **Run workflow** para testar.

Capítulo 11

# Segurança e privacidade

- O repositório não traz senhas, chaves, endereços nem dados pessoais. O `.env` é gerado na sua máquina e está no `.gitignore`, assim como a pasta `dados/`.
- Os documentos de exemplo foram escritos para o projeto; os manuais e a política de senhas são de uma empresa fictícia.
- O servidor escuta em `127.0.0.1` por padrão, e o Docker prende a porta ao mesmo endereço.
- Chave de acesso comparada em tempo constante (`CryptographicOperations.FixedTimeEquals`); no painel ela fica só na memória da aba.
- `Sonda:AllowedRoots` impede que alguém com a chave cadastre pastas fora das raízes permitidas.
- Cabeçalhos de segurança em todas as respostas: Content-Security-Policy sem scripts externos nem inline, `X-Frame-Options`, `nosniff` e `Referrer-Policy`.
- O painel monta o HTML com `textContent` e elementos criados um a um, então trechos de documentos nunca são interpretados como HTML.
- Scripts, estilos e comentários das páginas HTML indexadas são descartados na extração.
- Nada é enviado para fora: sem telemetria, sem CDN, sem chamadas externas.

Capítulo 12

# Solução de problemas

| Sintoma | Causa provável | O que fazer |
|---|---|---|
| “O índice já está aberto para gravação por outro processo” | O servidor está rodando e a linha de comando tentou indexar | Pare o servidor ou use o painel. Comandos de leitura funcionam normalmente |
| O painel mostra “só leitura” | Outro processo segura o `write.lock` | Feche o outro processo e reinicie o servidor |
| Nenhum resultado para uma palavra que existe | Ela é stopword ou o idioma detectado gerou outro radical | Use o Analisador na tela Termos para ver como a palavra é indexada |
| Uma fonte não indexa | A pasta não existe no servidor ou está fora de `AllowedRoots` | Confira o caminho na tela Fontes. No Docker, use o caminho de dentro do contêiner |
| Arquivos aparecem como falha | Maiores que `MaxFileMb` ou sem permissão de leitura | Aumente o limite ou ajuste as permissões |
| Acentos estranhos nos resultados | Arquivo em codificação diferente de UTF-8 e Latin-1 | Converta o arquivo para UTF-8 |
| “Checksum não confere” no verificar | Arquivo corrompido no disco ou cópia incompleta | Restaure o backup ou apague `dados/indice` e reindexe |
| Alterações na pasta não aparecem | Observar alterações desligado ou rede que não emite eventos | Clique em Indexar na fonte ou ligue Observar |
| Porta 8080 ocupada | Outro serviço na mesma porta | Mude `SONDA_PORT` no `.env` ou `Urls` no appsettings |